

AgroSearch — Motor de Busca Inteligente

UNIPÊ — Ciência da Computação · Tendências em Ciência da Computação

Prof. Me. Ricardo Roberto de Lima

Laboratório Prático 04 — Desafio Integrador

Ana Mária Lúcio de Sousa Dantas — RGM: 36003492

João Victor Barbosa Perazzo – RGM: 35548061

Ramon Fhelipe Vieira Marques – RGM: 36330809

Repositório: <https://github.com/ana-gadelha/agrosearch>

1. Objetivo

O AgroSearch é um protótipo de motor de busca para os manuais técnicos da AgroTech Solutions. O técnico digita uma consulta e o sistema mostra os documentos mais relevantes, ordenados pelo TF-IDF. Todo o processamento foi implementado sem bibliotecas de alto nível (como scikit-learn), conforme exigido no enunciado.

2. Como foi construído

- **Fase 1 — Pré-processamento:** tokenização com expressão regular; normalização (minúsculas e remoção de acentos com unicodedata); remoção de stopwords com uma lista própria; e stemming com um stemmer próprio, baseado em regras de corte de sufixos. Duas checkboxes na barra lateral ligam e desligam stopwords e stemming, e o vocabulário é atualizado na tela.
- **Fase 2 — Índice invertido:** dicionário que liga cada termo à lista de documentos em que ele aparece, exibido com st.json e st.dataframe (com o df de cada termo).
- **Fase 3 — Busca TF-IDF:** $TF = \text{ocorrências do termo} \div \text{total de termos do documento}$; $IDF = \log_{10}(N \div df)$; $TF-IDF = TF \times IDF$. A nota de cada documento é a soma do TF-IDF dos termos da consulta (TF-IDF acumulado). O ranking é exibido do maior para o menor, com o vencedor destacado em verde.
- **Bônus:** similaridade de cosseno entre o vetor TF-IDF da consulta e o de cada documento.

3. Exemplo de resultado

Consulta: "lagartas na soja" → termos após o pré-processamento: lagart, soj.

Ranking (maior → menor TF-IDF acumulado)

Documento	TF-IDF acumulado	Cosseno (bônus)	Texto
Doc 2	0.103300	0.309900	O controle biológico de lagartas na soja pode ser feito com a ves
Doc 4	0.077400	0.257200	Lagartas desfolhadoras causam grande prejuízo na cultura da sc
Doc 1	0.027700	0.061000	A soja requer irrigação constante durante o período de floração
Doc 3	0.000000	0.000000	A adubação verde com leguminosas melhora o nitrogênio no sol
Doc 5	0.000000	0.000000	A irrigação por gotejamento economiza água e é ideal para o cul

Cálculo termo a termo

Documento	Termo	TF	IDF	TF-IDF
Doc 1	lagart	0	0.3979	0
Doc 1	soj	0.125	0.2218	0.0277
Doc 2	lagart	0.1667	0.3979	0.0663
Doc 2	soj	0.1667	0.2218	0.037
Doc 3	lagart	0	0.3979	0
Doc 3	soj	0	0.2218	0
Doc 4	lagart	0.125	0.3979	0.0497
Doc 4	soj	0.125	0.2218	0.0277
Doc 5	lagart	0	0.3979	0
Doc 5	soj	0	0.2218	0

O vencedor foi o Doc 2 (TF-IDF acumulado = 0,1033), porque contém os dois termos num texto curto. O termo "lagart" tem peso maior que "soj" por ser mais raro: aparece em 2 documentos, contra 3 de "soj" (IDF 0,398 contra 0,222).

4. Observações e limitações

- Ao desativar a remoção de stopwords, o vencedor muda para o Doc 4, porque a palavra "na" passa a contar pontos. Isso mostra a importância dessa etapa.
- O stemmer por regras é simples e às vezes corta de forma imperfeita (ex.: "requer" → "requ").
- Por ser uma busca léxica, o sistema não reconhece sinônimos: "praga" não encontra "lagarta".